



Где что находится и как связано

Шесть агентов живут в облаке Anthropic; слушатель в Cloudflare принимает сообщения и решает, кого будить



Путь сообщения: где отсекается бесплатно и где тратятся токены

Слушатель отбрасывает лишнее до AI; токены Claude тратятся только когда агента действительно разбудили



ГДЕ И ЧТО ТРАТИТСЯ

токены Claude

Токены Claude (лимит подписки)

- 1 задача = 1 сессия агента; «Разобрал на 4 задачи» = 4 сессии
- по запросу: ~1–2,5 мин и 5–15 шагов модели (по журналу)
- отказ агента («не про это») — тоже сессия, но короткая
- фиксированно 5 сессий в сутки: 1 новости + 4 надзора
- повтор зависшего надзирателем = ещё одна сессия
- крупные ответы сервисов (до ~90 тыс. символов) агент кладёт в файл и читает выборочно

Whisper

Whisper (Cloudflare Workers AI)

- только голосовые, 1 вызов на сообщение; в пределах бесплатной дневной квоты Cloudflare

Apify \$

Apify (деньги)

- Покупки: 3 скрапера за запрос; Жильё: Островок и Авито
- потолок ≤ \$0,10 на вызов; бесплатный план — \$5 кредита в месяц

0 токенов

Бесплатно, без AI

- фильтр слушателя: дубли, боты, «помощь», «включи...», сообщения без слов агентов
- «Принял», паузы, журнал, веб-панель; MCP Туту и ВкусВилла, API Суточно

Когда агенты обращаются к AI и сколько уходит токенов

Пример — реальный запуск агента «Жильё» 07.10.2026: «отель в Сочи на 3 ночи с пятницы, с завтраком»

КТО И КОГДА ОБРАЩАЕТСЯ К AI

Слушатель 0 токенов	на каждое сообщение: фильтр, разбор задач, «Принял». Исключение — голосовое: один вызов Whisper
Агент по запросу токены Claude	только если слушатель нашёл слова агента и агент не на паузе. Каждый шаг от запуска до итога — ход модели
Инструменты агента 0 токенов	Туту, ВкусВилл, Arify, Суточно, Telegram, журнал — обычные сервисы. Но их ответ читает модель — это токены
Новости токены Claude	1 раз в день, 08:00: веб-поиск и дайджест
Надзиратель токены Claude	4 раза в сутки + повтор зависшего запроса (ещё одна сессия агента)
Журнал, веб-панель 0 токенов	только хранят и показывают

КАК УСТРОЕН ОДИН ШАГ АГЕНТА




Поэтому стоимость растёт от двух вещей: сколько шагов сделал агент и насколько большие ответы сервисов попали в контекст. Модель — Claude Sonnet; расход идёт из лимита подписки Claude.

ПРИМЕР: ОДИН ЗАПРОС К АГЕНТУ «ЖИЛЬЁ»

12 шагов модели	2 мин 26 с от запуска до итога	≈70 тыс. символов в контексте к концу	≈600 тыс. символов прочитано за 12 шагов
---------------------------	--	---	--

Что попало в контекст модели, тыс. символов (по журналу запуска)



Оценка в токенах	1 токен ≈ 2,5–3,5 символа русского текста и JSON; точных счётчиков в журнале нет		
≈20–28 тыс. новых токенов в контексте за запуск	≈170–240 тыс. токенов прочитано за 12 шагов — в основном из кэша	≈2,5–4 тыс. токенов написала модель: скрипт, команды, ответ	
+ служебная часть Claude Code (инструкции и описания инструментов) — на каждом шаге из кэша, в журнале не видна			

КАК РАСХОД ДЕРЖИТСЯ НИЗКИМ

- 30 вариантов Суточно и 15 отелей Островка легли в файлы — в контекст попала одна строка, модель берёт из файла только нужное
- отказ («отель был ужасный») — 2–3 шага вместо 12: агент сразу пишет skipped и молчит
- слушатель не будит агента без его слов; «помощь», «включи...», паузы и «Принял» — без AI
- резерв экономии: самый крупный кусок — ответ Туту (43 % контекста); можно просить меньше вариантов и полей