


Где что находится и как связано


Шесть агентов живут в облаке Anthropic; слушатель в Cloudflare принимает сообщения и решает, кого будить



Путь сообщения: где отсекается бесплатно и где тратятся токены

Персональные ассистенты · архитектура · 2/4

Слушатель отбрасывает лишнее до AI; токены Claude тратятся только когда агента действительно разбудили



ГДЕ И ЧТО ТРАТИТСЯ

токены Claude

Токены Claude (лимит подписки)

- 1 задача = 1 сессия агента; «Разобрал на 4 задачи» = 4 сессии
- по запросу: ~1–2,5 мин и 5–15 шагов модели (по журналу)
- отказ агента («не про это») — тоже сессия, но короткая
- фиксированно 5 сессий в сутки: 1 новости + 4 надзора
- повтор зависшего надзирателем = ещё одна сессия
- крупные ответы сервисов (до ~90 тыс. символов) агент кладёт в файл и читает выборочно

Whisper

Whisper (Cloudflare Workers AI)

- только голосовые, 1 вызов на сообщение; в пределах бесплатной дневной квоты Cloudflare

Apify \$

Apify (деньги)

- Покупки: 3 скрапера за запрос; Жильё: Островок и Авито
- потолок ≤ \$0,10 на вызов; бесплатный план — \$5 кредита в месяц

0 токенов

Бесплатно, без AI

- фильтр слушателя: дубли, боты, «помощь», «включи...», сообщения без слов агентов
- «Принял», паузы, журнал, веб-панель; MCP Туту и ВкусВилла, API Суточно

Когда агенты обращаются к AI и сколько уходит токенов

Пример — реальный запуск агента «Жильё» 07.10.2026: «отель в Сочи на 3 ночи с пятницы, с завтраком»

КТО И КОГДА ОБРАЩАЕТСЯ К AI

Слушатель 0 токенов	на каждое сообщение: фильтр, разбор задач, «Принял». Исключение — голосовое: один вызов Whisper
Агент по запросу токены Claude	только если слушатель нашёл слова агента и агент не на паузе. Каждый шаг от запуска до итога — ход модели
Инструменты агента 0 токенов	Туту, ВкусВилл, Arify, Суточно, Telegram, журнал — обычные сервисы. Но их ответ читает модель — это токены
Новости токены Claude	1 раз в день, 08:00: веб-поиск и дайджест
Надзиратель токены Claude	4 раза в сутки + повтор зависшего запроса (ещё одна сессия агента)
Журнал, веб-панель 0 токенов	только хранят и показывают

КАК УСТРОЕН ОДИН ШАГ АГЕНТА




Поэтому стоимость растёт от двух вещей: сколько шагов сделал агент и насколько большие ответы сервисов попали в контекст. Модель — Claude Sonnet; расход идёт из лимита подписки Claude.

ПРИМЕР: ОДИН ЗАПРОС К АГЕНТУ «ЖИЛЬЁ»

12 шагов модели	2 мин 26 с от запуска до итога	≈70 тыс. символов в контексте к концу	≈600 тыс. символов прочитано за 12 шагов
---------------------------	--	---	--

Что попало в контекст модели, тыс. символов (по журналу запуска)



Оценка в токенах	1 токен ≈ 2,5–3,5 символа русского текста и JSON; точных счётчиков в журнале нет		
≈20–28 тыс. новых токенов в контексте за запуск	≈170–240 тыс. токенов прочитано за 12 шагов — в основном из кэша	≈2,5–4 тыс. токенов написала модель: скрипт, команды, ответ	
+ служебная часть Claude Code (инструкции и описания инструментов) — на каждом шаге из кэша, в журнале не видна			

КАК РАСХОД ДЕРЖИТСЯ НИЗКИМ

- 30 вариантов Суточно и 15 отелей Островка легли в файлы — в контекст попала одна строка, модель берёт из файла только нужное
- отказ («отель был ужасный») — 2–3 шага вместо 12: агент сразу пишет skipped и молчит
- слушатель не будит агента без его слов; «помощь», «включи...», паузы и «Принял» — без AI
- резерв экономии: самый крупный кусок — ответ Туту (43 % контекста); можно просить меньше вариантов и полей

Один управляющий агент или команда агентов

Почему у ассистентов фабрика узких агентов, а не один «на всё» — на примере сообщения из 4 дел



ЭКОНОМИЯ НА ПРИМЕРЕ «ЗАВТРАК + МЯЧ + ПОЕЗД + ОТЕЛЬ»

один агент команда агентов

Сколько символов прочитала модель



–60 %

в 2–3 раза меньше

Время до ответа в чат



–70 %

в 3–4 раза быстрее

Самый большой контекст на шаге



–72 %


в 3,5 раза меньше

Реплика «спасибо» в чате



–100 %

бесплатно



СРАВНЕНИЕ ПО КРИТЕРИЯМ

	Один агент	Команда агентов
Расход токенов	в 2–3 раза больше	меньше
Скорость ответа	дела по очереди	параллельно
Качество ответов	длинная инструкция	короткий сценарий
Сломался сервис (например, Туту)	ломает весь ответ	ломает одного
Модель под задачу	одна, самая сильная	Haiku или Sonnet
Доступы и ключи	все ключи у одного	только нужные
Паузы, расписание, журнал	общие на всех	по каждому агенту
Добавить нового агента	правка общего сценария	по шаблону
Связанные дела (поезд + отель)	видит всё сразу	частично, через контекст
Запуски Routines	1 на сообщение	1 на каждое дело
Старт с 1–2 задачами	проще	избыточно

ВЫВОД

Оставляем команду агентов. На сообщении из 4 дел — примерно в 2–3 раза меньше токенов и в 3–4 раза быстрее; поломка одного сервиса не роняет остальных; у каждого агента своя модель и только свои ключи.

ДАЛЬШЕ — ПО ЗАПРОСУ

- дешёвый ИИ-маршрутизатор (Haiku) — только для сообщений, где слова агентов не совпали.
- режим «поездка»: Жильё запускается после Поездки, с датой прибытия из их ответа.