



Где что находится и как связано

Шесть агентов живут в облаке Anthropic; слушатель в Cloudflare принимает сообщения и решает, кого будить



Путь сообщения: где отсекается бесплатно и где тратятся токены

Слушатель отбрасывает лишнее до AI; токены Claude тратятся только когда агента действительно разбудили



ГДЕ И ЧТО ТРАТИТСЯ

токены Claude

Токены Claude (лимит подписки)

- 1 задача = 1 сессия агента; «Разобрал на 4 задачи» = 4 сессии
- по запросу: ~1–2,5 мин и 5–15 шагов модели (по журналу)
- отказ агента («не про это») — тоже сессия, но короткая
- фиксированно 5 сессий в сутки: 1 новости + 4 надзора
- повтор зависшего надзирателем = ещё одна сессия
- крупные ответы сервисов (до ~90 тыс. символов) агент кладёт в файл и читает выборочно

Workers AI

Cloudflare Workers AI (не Claude)

- голосовое: Whisper, 1 вызов на сообщение
- текст без слов агентов, похожий на просьбу: 1 короткий вопрос Llama «кому это?» (≤ 200 в сутки)
- всё — в пределах бесплатной дневной квоты Cloudflare

Apify \$

Apify (деньги)

- Покупки: 3 скрапера за запрос; Жильё: Островок и Авито
- потолок ≤ \$0,10 на вызов; бесплатный план — \$5 кредита в месяц

0 токенов

Бесплатно, без AI

- фильтр слушателя: дубли, боты, «помощь», «включи...», слова агентов, «спасибо» и «ок»
- «Принял», паузы, журнал, веб-панель; MCP Туту и ВкусВилла, API Суточно

Когда агенты обращаются к AI и сколько уходит токенов

Пример — реальный запуск агента «Жильё» 07.10.2026: «отель в Сочи на 3 ночи с пятницы, с завтраком»

КТО И КОГДА ОБРАЩАЕТСЯ К AI

Слушатель 0 токенов	фильтр, разбор задач, «Принял» — без AI. Workers AI (не Claude): голосовое → Whisper; нет слов агентов → «кому это?»
Агент по запросу токены Claude	только если слушатель нашёл слова агента (или Workers AI понял по смыслу) и агент не на паузе. Каждый шаг — ход модели
Инструменты агента 0 токенов	Туту, ВкусВилл, Arify, Суточно, Telegram, журнал — обычные сервисы. Но их ответ читает модель — это токены
Новости токены Claude	1 раз в день, 08:00: веб-поиск и дайджест
Надзиратель токены Claude	4 раза в сутки + повтор зависшего запроса (ещё одна сессия агента)
Журнал, веб-панель 0 токенов	только хранят и показывают

КАК УСТРОЕН ОДИН ШАГ АГЕНТА




Поэтому стоимость растёт от двух вещей: сколько шагов сделал агент и насколько большие ответы сервисов попали в контекст. Модель — Claude Sonnet; расход идёт из лимита подписки Claude.

ПРИМЕР: ОДИН ЗАПРОС К АГЕНТУ «ЖИЛЬЁ»

12 шагов модели	2 мин 26 с от запуска до итога	≈70 тыс. символов в контексте к концу	≈600 тыс. символов прочитано за 12 шагов
---------------------------	--	---	--

Что попало в контекст модели, тыс. символов (по журналу запуска)



Оценка в токенах	1 токен ≈ 2,5–3,5 символа русского текста и JSON; точных счётчиков в журнале нет		
≈20–28 тыс.	≈170–240 тыс.	≈2,5–4 тыс.	
новых токенов в контексте за запуск	токенов прочитано за 12 шагов — в основном из кэша	токенов написала модель: скрипт, команды, ответ	
+ служебная часть Claude Code (инструкции и описания инструментов) — на каждом шаге из кэша, в журнале не видна			

КАК РАСХОД ДЕРЖИТСЯ НИЗКИМ

- 30 вариантов Суточно и 15 отелей Островка легли в файлы — в контекст попала одна строка, модель берёт из файла только нужное
- отказ («отель был ужасный») — 2–3 шага вместо 12: агент сразу пишет skipped и молчит
- агента будят только по делу: слова или «кому это?» от Workers AI (не Claude); «спасибо», «помощь», паузы — без AI
- резерв экономии: самый крупный кусок — ответ Туту (43 % контекста); можно просить меньше вариантов и полей

Один управляющий агент или команда агентов

Почему у ассистентов фабрика узких агентов, а не один «на всё» — на примере сообщения из 4 дел



ЭКОНОМИЯ НА ПРИМЕРЕ «ЗАВТРАК + МЯЧ + ПОЕЗД + ОТЕЛЬ»

один агент команда агентов

Сколько символов прочитала модель



–60 %

в 2–3 раза меньше

Время до ответа в чат



–70 %

в 3–4 раза быстрее

Самый большой контекст на шаге



–72 %


в 3,5 раза меньше

Реплика «спасибо» в чате



–100 %

бесплатно



СРАВНЕНИЕ ПО КРИТЕРИЯМ

	Один агент	Команда агентов
Расход токенов	в 2–3 раза больше	меньше
Скорость ответа	дела по очереди	параллельно
Качество ответов	длинная инструкция	короткий сценарий
Сломался сервис (например, Туту)	ломает весь ответ	ломает одного
Модель под задачу	одна, самая сильная	Haiku или Sonnet
Доступы и ключи	все ключи у одного	только нужные
Паузы, расписание, журнал	общие на всех	по каждому агенту
Добавить нового агента	правка общего сценария	по шаблону
Связанные дела (поезд + отель)	видит всё сразу	частично, через контекст
Запуски Routines	1 на сообщение	1 на каждое дело
Старт с 1–2 задачами	проще	избыточно

ВЫВОД

Оставляем команду агентов. На сообщении из 4 дел — примерно в 2–3 раза меньше токенов и в 3–4 раза быстрее; поломка одного сервиса не роняет остальных; у каждого агента своя модель и только свои ключи.

СДЕЛАНО И ДАЛЬШЕ

Сделано 08.10: ИИ-маршрутизатор на Workers AI — только когда слов агентов нет, в бесплатной квоте.

По запросу: режим «поездка» — Жильё запускается после Поездки, с датой прибытия из их ответа.